Guida docente · Lezione 4

ITS MAKER Bologna · Lezione 4 · 12 novembre 2026 · Unsloth Studio nella macchina virtuale

Documento riservato al docente.

Che cosa si fa

Il caso è la P03 della lezione 3, con un cambio: il modello non è più un servizio esterno ma gira nella macchina virtuale (VM) di ogni studente. Il filo della lezione è l'assistente di reparto che «non fa uscire i registri».

Parte	Dove	Che cosa fanno gli studenti	Consegna
1. Installare	VM, PowerShell	Eseguono l'installer di Unsloth Studio	
2A. Parola successiva	Computer reale, browser	Prevedono e poi osservano l'effetto della temperatura in Transformer Explainer	misure_VM.txt: previsioni
2B. Token	Computer reale, browser	Contano i token del registro e di una versione più breve scritta da loro, e si scambiano le versioni brevi	misure_VM.txt: token
3A. Primo avvio	VM, Studio	Password, memoria prima del caricamento, estrazione dello zip o scarico, Search e Tools disattivati	misure_VM.txt: misure
3B. Memoria e tempi	VM, Studio, Gestione attività	Confrontano la stima di Studio con la memoria misurata, con Context Length su Auto e su 8192; secondi, tok/s e token con testo breve e con il registro intero	misure_VM.txt: misure, spiegazione
3C. Parametri	VM, Studio	In coppia: criteri insieme, impostazioni divise (uno Temperature, l'altro Top P oppure Top K, a scelta), scelta insieme	misure_VM.txt: criteri, scelta
4A. Istruzioni	VM, Studio	Scrivono le istruzioni e le incollano in System Prompt	istruzioni_assistente_P03.txt
4B. Prova del compagno	VM, Studio	Inventano casi e tranelli per l'assistente del compagno	casi_di_prova.txt
4C. Correzione	VM, Studio	Correggono le istruzioni dove emergono falle	istruzioni_assistente_P03.txt

L'installazione e il caricamento del modello dipendono dalla rete e non si possono accorciare in aula. Per questo la parte 2 si fa mentre l'installazione procede: le due cose avvengono in luoghi diversi (VM e computer reale).

Se l'installazione è lenta (decisione del 5 novembre 2026). Una sola regola, in due passi:

1. Alla fine della parte 2 l'installazione non è finita su una VM: ognuno scrive il proprio istruzioni_assistente_P03.txt (4A, punto 1) in Blocco note, senza Studio. Fai vedere le slide 15–16, che spiegano il System Prompt: se l'anticipo riguarda solo alcune coppie, mostrale a quelle coppie dal tuo

portatile o rimandale alla parte 4A della consegna; proiettale per tutti solo se riguarda la maggior parte della classe. La regola dell'esempio dopo il tentativo non cambia; le prove restano in Studio.

2. Finita la scrittura anticipata: le coppie con almeno una VM con Studio aperto proseguono (a turno, se ne funziona una sola); le coppie senza Studio passano al ramo di riserva («Se Studio non parte»). Se più di metà della classe è senza Studio, il ramo vale per tutti. Questa è l'unica soglia: le altre sezioni la richiamano.

Tutti e tre i file .txt si scrivono con Blocco note dentro la VM, che si può usare anche durante la parte 2. Ogni studente consegna i propri tre file.

Prima di giovedì 12 novembre

Da preparare a casa

1. Modello già pronto. Il modello pesa circa 2 GB e la rete della scuola è la stessa per tutti: se lo scaricano tutti insieme, il rischio è quello visto con Copilot nella lezione 3. Scaricalo tu una volta sola, con Studio, sul tuo portatile (Select model → unsloth/Qwen3.5-2B-GGUF → UD-Q4_K_XL) e prepara lo zip come nella sezione «Copia del modello». Porta più chiavette, una ogni 4–5 studenti: lo zip è di circa 1,9 GB. Come entra nella VM (da scegliere e provare, nulla è stato provato su VMware): con VMware Workstation la chiavetta si può collegare direttamente alla VM (menu VM, Removable Devices, la chiavetta, Connect), oppure lo zip si copia sul computer reale e si trascina nella finestra della VM. Mostra la via scelta alla classe nella parte 1. Le chiavette girano durante la parte 1 e la parte 2: ognuno copia lo zip sul Desktop della VM subito dopo aver avviato l'installazione e restituisce la chiavetta senza aspettare l'estrazione; l'estrazione in hub avviene in 3A. Se nessuna via funziona, lo scarico dalla rete va fatto solo su alcune VM e le coppie lavorano a turno su quelle: non su tutte insieme. Con l'estrazione di Windows («Estrai tutto») compare una sottocartella con il nome dello zip: va tolta, perché Studio potrebbe non trovare il modello (non provato).

2. Pubblica su Teams prima della lezione studenti/ATTIVITA_LEZIONE4.docx e Registro_P03_13-15_ottobre_2026.txt (cartella studenti/), e crea il compito per i tre file .txt. Gli studenti scaricano il registro sul computer reale e, aprendo Teams nel browser della VM, anche nella VM; consegnano da Teams.

3. Esempio di istruzioni. studenti/da_pubblicare_dopo_parte_4C/ESEMPIO_ISTRUZIONI_ASSISTENTE_P03.txt non si pubblica prima: solo dopo la parte 4C.

4. Windows nella VM. Verifica che dalla VM si raggiunga internet e Teams, con l'account studente e l'eventuale verifica in due passaggi. Il copia e incolla tra computer reale e VM (VMware: appunti condivisi, trascinamento, cartella condivisa o USB) è una comodità, tranne per lo zip del modello (punto 1). Se non funziona, gli studenti scrivono a mano il comando di installazione dalla slide 5, controllandolo lettera per lettera; scaricano il registro da Teams nella VM e consegnano da lì; il testo delle istruzioni da mandare al compagno lo scrivono in un messaggio su Teams.

Controlli prima dell'aula

Non è stato possibile provare nulla sulle VM della scuola né dalla rete della scuola. La colonna «Esito» resta da compilare in aula o prima, sulla prima VM disponibile.

Controllo	Che cosa verificare	Esito
Installer su Windows	Il comando della slide 5 (con $env:UNSLOTH_NO_TORCH=1) termina senza errori su una VM Windows con 8 GB di RAM; se fallisce, provare la forma normale, senza quella parte. Leggere in Gestione attività, scheda Rete, quanti dati scarica l'installer e moltiplicare per il numero di VM	
Permessi	L'installazione funziona con l'utente degli studenti, senza amministratore	

Controllo	Che cosa verificare	Esito
Spazio su disco	Almeno 8 GB liberi nella VM: l'installazione occupa circa 2,3 GB, il modello circa 2 GB (Studio segnala poco spazio libero)	
Primo avvio	Dopo l'installazione compare la domanda se avviare Studio; http://127.0.0.1:8888 apre la pagina di creazione della password. Chiusa la finestra, in una nuova PowerShell unsloth studio -p 8888 riavvia Studio e chiede la password	
Modello	unsloth/Qwen3.5-2B-GGUF, versione UD-Q4_K_XL: il modello si carica con 8 GB di RAM e risponde in italiano	
Memoria e contesto	Con Context Length su Auto e poi su 8192 (Reload model): memoria in uso nella VM e tempo con il registro intero; la VM resta utilizzabile. Lo script docente/prova_vm/misura_vm.py misura memoria e tempi senza interfaccia, ma richiede Python e il corpus del laboratorio e non è stato provato su Windows	
Search e Tools	Attivi di partenza; dopo il clic diventano grigi anche nella versione scaricata dall'installer di Windows	
Copia del modello	Lo zip estratto in %USERPROFILE% \.cache\huggingface\hub (cartella creata da Esplora file se manca) viene riconosciuto da Studio: compare in On Device, UD-Q4_K_XL, e si carica	
Memoria dell'host	Con la VM da 8 GB accesa e due schede del browser aperte sul computer reale (Transformer Explainer) la memoria del PC reale regge	
Rete	Transformer Explainer e Tokenizer Playground si aprono dalla rete della scuola, con tutte le postazioni accese insieme; leggere quanti dati scarica Transformer Explainer per caricare il modello nel browser. Per decidere vale la regola di «Se l'installazione è lenta»	
Passaggio dei file	Teams si apre nel browser della VM; il testo di istruzioni_assistente_P03.txt si manda al compagno con un messaggio su Teams; i tre file si caricano dal browser della VM, o si copiano sul computer reale	

Controllo	Che cosa verificare	Esito
Zip del modello	Lo zip passa dalla chiavetta alla VM (collegamento USB di VMware o trascinamento) e si estrae in %USERPROFILE% \.cache\huggingface\hub; misurare tempo di copia ed estrazione	
Context Length	Ordine del controllo: prima «si può impostare prima del caricamento?» (prova senza rischio), poi «la stima di Studio cambia senza Reload?», poi «Studio ricorda l'ultimo valore dopo la riapertura?», per ultimo il caricamento con Auto, che può bloccare la VM: «Studio riduce da solo il contesto alla memoria libera?» (lo fa pensare --fit on tra i parametri del motore su Linux, ma non è stato visto con poca RAM). Tre esiti per la classe: (a) si può impostare prima: dì di caricare subito con 8192 e di scrivere nella prima riga della tabella di 3B (Context Length su Auto) solo la stima di Studio; (b) non si può impostare prima ma Auto regge: si segue la consegna; (c) Auto blocca e il valore non si può impostare prima né resta: quella VM non carica il modello, la coppia lavora a turno sull'altra VM e, se il blocco c'è su entrambe, passa al ramo di riserva. Chi ha il blocco scrive «bloccato» nella prima riga della tabella di 3B, al posto della stima e della memoria	
Copilot	Con l'account studente accetta in un solo messaggio le istruzioni e il registro intero (circa 10.600 caratteri): serve al ramo di riserva della parte 4. Nella lezione 2 il registro si incollava in quattro parti	
System Prompt e regolazioni	Aprendo una nuova conversazione, System Prompt, Temperature, Top P e Top K restano quelli impostati, con il modello caricato e dopo almeno una risposta. Su Linux il System Prompt è rimasto dopo «New chat» (senza modello caricato) e dopo Reload model (con modello caricato); Temperature, Top P e Top K non sono stati verificati. In 4B e 4C gli studenti alternano comunque le istruzioni del compagno e le proprie: le consegne chiedono di controllare Run settings prima di provare	
Teams nella VM	Accesso con l'account studente, anche con la verifica in due passaggi; caricamento dei tre file	

Che cosa è stato provato

Provato il 5 novembre 2026 sul portatile del docente, Linux, versione di Unsloth Studio 2026.11.2. Non è Windows, non è la VM, non è la rete della scuola.

• Installazione. install.sh con UNSLOTH_NO_TORCH=1 (modalità senza PyTorch, solo GGUF) termina senza errori. Circa 2,3 GB su disco, circa 15 minuti con una connessione domestica; il tempo è dominato dalla rete, non dal processore.

• Primo avvio. unsloth studio -p <porta> parte; la pagina chiede di creare una password di almeno 8 caratteri.

• Interfaccia. Casella Select model; ricerca per indirizzo; elenco delle versioni (UD-Q4_K_XL indicata come consigliata); scheda On Device; pannello Run settings con Estimated Memory Usage, Context Length, System Prompt, Temperature (0,6 di partenza), Top P (0,95), Top K (20). Nella casella dei messaggi Search e Tools sono attivi di partenza (verdi) e si disattivano con un clic (grigi); la scelta resta anche dopo il riavvio.

• Download. unsloth/Qwen3.5-2B-GGUF, UD-Q4_K_XL: Studio indica 2,0 GB (il modello da 1,3 GB e il file per le immagini). Con il download predefinito la barra è rimasta ferma a lungo e il registro del programma segnalava «connection struggling»; con HF_HUB_DISABLE_XET=1 è partito, a circa 1,1–1,8 MB/s su quella rete.

• Cartella del modello copiata. Una copia della cartella del modello, senza i collegamenti simbolici e senza blobs, messa nella cartella hub, viene riconosciuta da Studio (scheda On Device, UD-Q4_K_XL, 1,3 GB) e il modello si carica.

• Risposte, solo CPU (scheda grafica nascosta con CUDA_VISIBLE_DEVICES=-1; UNSLOTH_CPU_THREADS=4 impostato, ma non verificato che limiti anche il motore del modello; 15,6 GB di RAM nel portatile): registro intero (circa 3,2k token mostrati da Studio) più una domanda, circa 25 secondi, 15–16 tok/s. Con Context Length su Auto il processo del modello occupava circa 5,4 GB, con 8192 circa 2,5 GB; Estimated Memory Usage indicava 6,49 GiB contro 3,34 GiB. Con la scheda grafica: circa 10 secondi, 61 tok/s.

• Istruzioni di sistema. Il modello risponde in italiano. Con la prima versione dell'esempio (prosa lunga) non ha mai fatto una domanda di chiarimento e ha ripetuto «Dato non presente nel registro» anche a domande con risposta nel registro. Con la versione a regole numerate ora in ESEMPIO_ISTRUZIONI_ASSISTENTE_P03.txt, alla domanda «Qual era la temperatura dell'olio?» ha risposto «A quale giorno e ora ti riferisci?». Provato un solo caso, un solo tentativo: le regole 1–3 non sono verificate oltre questo; la regola 4 non è provata.

• Persistenza. Il campo System Prompt non si è svuotato aprendo una nuova chat né dopo Reload model (5 novembre 2026, versione 2026.11.2, Linux). La nuova chat è stata provata senza modello caricato.

Non provato: l'installer install.ps1 su Windows; Windows nella VM con 8 GB di RAM; i permessi degli studenti; la rete della scuola; il tempo di installazione con più postazioni insieme; il comportamento della memoria quando la VM ha meno RAM libera di quella richiesta (Studio dovrebbe ridurre il contesto da solo con Auto, ma non è stato visto); i tempi con i processori della VM.

Copia del modello

Preparazione sul tuo portatile (Linux), dopo aver scaricato il modello con Studio:

```
mkdir -p ~/modello_per_VM
cp -rL ~/.cache/huggingface/hub/models--unsloth--Qwen3.5-2B-GGUF ~/modello_per_VM/
rm -rf ~/modello_per_VM/models--unsloth--Qwen3.5-2B-GGUF/blobs ~/modello_per_VM/models--unsloth--Qwen3.5-2B-GGUF/.transport*
cd ~/modello_per_VM && zip -r modello_Qwen3.5-2B.zip models--unsloth--Qwen3.5-2B-GGUF
```

cp -rL copia i file veri al posto dei collegamenti simbolici, che Windows non gestisce. Nella VM lo zip va estratto in %USERPROFILE%\.cache\huggingface\hub (barra dell'indirizzo di Esplora file), in modo che dentro hub ci sia la cartella models--unsloth--Qwen3.5-2B-GGUF; se .cache, huggingface o hub non esistono, si creano uno alla volta. Il file è di circa 1,9 GB. L'estrazione su Windows non è stata provata.

Svolgimento

Parte 1 · Installazione

All'ingresso fai accendere la VM e accedere a Windows, prima delle slide 1–3. Poi fai partire tutti insieme: PowerShell, incolla, Invio. Passa tra i banchi per le prime schermate: è qui che compaiono i problemi. Chi vede un errore in rosso ti chiama senza chiudere la finestra.

Controllo di Context Length, durante la parte 2. Avvia l'installazione anche sulla tua postazione di prova, oppure segui la prima VM che la finisce. Fai il controllo della riga «Context Length» dei controlli prima dell'aula, nell'ordine indicato lì, e comunica la decisione alla classe prima che arrivi a 3A, punto 5: le consegne fanno aspettare la tua indicazione prima di cliccare Select model. Finché il controllo non è finito dì: «caricate con Auto tenendo aperta Gestione attività; se la memoria arriva quasi al massimo chiudete PowerShell come in 3A e scrivete "bloccato" nella prima riga della tabella di 3B».

Con l'esito (a) dì anche che nella riapertura di Studio (consegna, 3A) Context Length si porta a 8192 prima di Select model, per non ripetere il blocco.

Se il comando con $env:UNSLOTH_NO_TORCH=1; non funziona, prova la forma normale, irm https://unsloth.ai/install.ps1 | iex: scarica anche PyTorch ed è molto più pesante.

Decidi presto se il modello arriva dallo zip o dalla rete: il file è lo stesso per tutti.

Parte 2 · Browser del computer reale

Qui la classe lavora mentre l'installazione procede. Non spiegare prima: lascia che prevedano e poi guardino.

• Transformer Explainer. Domande utili: che cosa succede alla barra più lunga quando la temperatura sale? Perché a temperatura bassa il modello sceglie quasi sempre la stessa parola? È un modello molto piccolo, in inglese: non giudicare la qualità delle frasi.

• Tokenizer Playground. Il registro intero (24 note, circa 1.700 parole) è lungo: serve a far vedere che cosa pesa. Raccogli i numeri di token alla lavagna con il nome del tokenizzatore scelto: cambia il valore. Lo scambio delle versioni brevi fa vedere che cosa si perde quando si riscrive un testo.

Parte 3 · Studio

• Primo avvio. La password serve ogni volta; i fogli con le password evitano blocchi più avanti. La memoria prima del caricamento si legge prima di scegliere il modello. Search e Tools sono attivi di partenza: chi non li disattiva può far partire una ricerca su internet o l'esecuzione di codice nella VM.

• Misure. Gli studenti confrontano tre cose: la stima di Studio (Estimated Memory Usage) con la memoria misurata in Gestione attività; la memoria con Context Length su Auto e con 8192; il numero di token del Tokenizer Playground con quello mostrato in alto da Studio. La memoria del modello è la memoria in uso dopo il caricamento meno quella misurata prima. La domanda breve e il registro intero mostrano l'effetto del testo lungo sul tempo. Se la VM ha poca RAM libera, con Auto Studio può scegliere un contesto grande (nel portatile 262.144 token, circa 5,4 GB): se la VM rallenta o si blocca, fai portare subito Context Length a 8192 e fai riaprire Studio come nella consegna. Il registro intero ne usa circa 3.200. Il cambio vale dopo Reload model: se non si ricarica al primo clic, si clicca ancora. Raccogli da tutte le coppie memoria a modello caricato, secondi e tok/s con il registro intero: servono per scegliere il modello delle lezioni 5–7.

• Parametri. In coppia: criteri e richiesta insieme, poi le prove divise per regolazione (uno Temperature, l'altro Top P oppure Top K, a scelta, ognuno nella propria VM), una nuova conversazione per ogni prova. I valori di partenza li prova chi segue la Temperature, controllando la risposta già ottenuta in 3B con i criteri della coppia e rifacendo la prova solo se la richiesta scritta in 3C è diversa; ognuno prova poi un valore basso e uno alto. Non cercare un valore «giusto»: un'impostazione con valori bassi e una con valori alti possono dare entrambe una risposta valida; conta come la giustificano. Se due impostazioni danno la stessa risposta, è un risultato. A parità di richiesta il modello può dare risposte diverse: chiedi di ripetere la prova solo alle coppie le cui due impostazioni hanno dato risposte diverse. Valori di partenza visti su Linux: Temperature 0,6, Top P 0,95, Top K 20; su Windows da verificare.

• Se le risposte sono lente (decisione del 5 novembre 2026). Una regola legata a un evento, non a una durata: se in 3B la risposta con il registro intero è molto più lenta dei 25 secondi visti su Linux, in 3C ognuno prova un solo valore della propria regolazione (il basso o l'alto, a scelta) invece di due; i valori di

partenza restano quelli di 3B. Dillo a voce alla classe prima di 3C e controlla che in «Scelta» compaia una riga per prova. Le prove di 4B e 4C non cambiano. I dati sulla velocità raccolti in 3B servono comunque per le lezioni 5–7.

Parte 4 · Istruzioni

• Gli studenti scrivono le istruzioni senza esempio. Se chiedono «come si scrive?», rimanda alle quattro voci della consegna.

• La prova del compagno richiede il passaggio del testo delle istruzioni, con un messaggio su Teams: verifica che funzioni per tutte le coppie. Ogni prova è una nuova conversazione con registro e domanda in un solo messaggio; in 4C gli studenti rimettono nel System Prompt le proprie istruzioni prima di riprovare.

• Casi che sanno inventare: dato assente nel registro, domanda senza giorno, due note che danno valori diversi, richiesta di un'azione sulla macchina, domanda fuori dal registro. Non suggerirli: li devono trovare loro.

• Esempio di istruzioni. Dopo la parte 4C pubblica ESEMPIO_ISTRUZIONI_ASSISTENTE_P03.txt e chiedi di confrontarlo con le proprie: che cosa manca? Che cosa è inutile? Quale regola ha cambiato il comportamento? Non presentarlo come soluzione: è provato su un solo caso. Se la classe vede un comportamento diverso dal tuo, è un dato valido e va discusso.

Chiusura

Ordine: fai consegnare i tre file; poi pubblica l'esempio di istruzioni e fai il confronto con le istruzioni degli studenti; poi le tre domande della slide 22. In questo modo l'esempio non può cambiare i file consegnati. Risposte attese, dai valori misurati in aula: (1) la memoria dipende dal modello e da Context Length, che si fissa al caricamento; il testo lungo aumenta i token e i secondi di attesa. Con l'esito (b) si confrontano le misure con Auto e con 8192, con l'esito (a) le stime di Studio, con l'esito (c) il blocco è il dato; (2) con la temperatura alta il modello sceglie più spesso parole meno probabili e le risposte variano di più; se i dati restano giusti lo dice il controllo con i criteri, non il valore della temperatura; (3) un caso di prova che ha fatto cambiare o confermare una regola delle proprie istruzioni, con il motivo. Se un valore misurato non coincide, è un dato da discutere.

Valori di riferimento del registro

Ricavati dallo script del generatore dal testo di Registro_P03_13-15_ottobre_2026.txt.

Le tabelle elencano ogni riga in cui il valore compare, con data e ora della nota. Dove il valore è uguale a quello della riga precedente è segnato come ripetizione: non è una nuova lettura.

Dato	Valore
Note nel registro	24
Parole del registro	1736 (testo intero, parole separate da spazi)
Limite di allarme dell'olio	65 °C
Inizio del fermo	14/10/2026 · 14:20: allarme, olio a 78 °C, contatore a 2.480 pezzi
Fine del fermo	14/10/2026 · 15:05: la pressa riprende a produrre
Durata del fermo	45 minuti, calcolati dagli orari e uguali a quelli scritti nella nota di ripartenza
Causa del fermo	filtro intasato, constatato il 14/10/2026 · 14:34
Filtro sostituito	14/10/2026 · 14:42: sostituzione completata con FLT-992
Codice filtro FLT-992	in 6 note (6 volte)
Codice pezzo A17	in 14 note (15 volte)

Dato	Valore
Temperature dell'olio	16 righe: 15 letture e 1 ripetizione
Contatore dei pezzi	7 righe: 5 letture e 2 ripetizioni
Controlli dei pezzi	4 note

Temperatura dell'olio

Data e ora	Valore
13/10/2026 · 08:00	48 °C
13/10/2026 · 10:10	57 °C
13/10/2026 · 14:00	60 °C
13/10/2026 · 16:00	59 °C
14/10/2026 · 08:00	49 °C
14/10/2026 · 09:30	55 °C
14/10/2026 · 13:30	61 °C
14/10/2026 · 14:10	64 °C
14/10/2026 · 14:20	78 °C
14/10/2026 · 14:24	78 °C (ripetizione del valore precedente)
14/10/2026 · 14:52	58 °C
14/10/2026 · 15:20	59 °C
15/10/2026 · 08:00	48 °C
15/10/2026 · 08:30	53 °C
15/10/2026 · 10:00	58 °C
15/10/2026 · 12:00	59 °C

Contatore dei pezzi

Data e ora	Valore
13/10/2026 · 08:00	1.200 pezzi
13/10/2026 · 08:20	1.280 pezzi
14/10/2026 · 09:30	1.960 pezzi
14/10/2026 · 14:20	2.480 pezzi
14/10/2026 · 14:28	2.480 pezzi (ripetizione del valore precedente)
14/10/2026 · 14:52	2.480 pezzi (ripetizione del valore precedente)

Data e ora	Valore
14/10/2026 · 15:20	2.540 pezzi

Controlli dei pezzi

Data e ora	Pezzi controllati
13/10/2026 · 08:20	10 pezzi
14/10/2026 · 09:30	10 pezzi
14/10/2026 · 15:20	10 pezzi
15/10/2026 · 08:30	10 pezzi

Dati che il registro non contiene, utili per i tranelli: nome del tecnico, contatore del 15 ottobre, il motivo per cui il filtro si è intasato (il registro dice solo che era intasato), nome del responsabile del turno.

Se Studio non parte

La regola per decidere è quella di «Se l'installazione è lenta» (sopra): evento e non tempo, in due passi. Se una sola VM della coppia funziona, la coppia lavora a turno su quella. Le alternative sono nella consegna degli studenti («Se Unsloth Studio non parte»).

Attività	Con Studio	Senza Studio
2A Parola successiva	Transformer Explainer	Uguale
3B Memoria	Misure nella VM	Calcolatore OCTOO nel browser del computer reale, con modello da 2 miliardi di parametri a 4 bit, contesto 8192 e massimo: stima per schede grafiche, non misura della VM
3C Parametri	Prove divise in Studio	Si usano le distribuzioni di Transformer Explainer: la coppia scrive i criteri, sceglie una temperatura e la motiva; in «Scelta» segna che ha lavorato senza Studio
4 Istruzioni	System Prompt di Studio	Le istruzioni si provano come primo messaggio in Copilot, con il registro sotto, scrivendo che non è il campo di sistema e che il registro esce dal reparto. Se Copilot non risponde o non accetta il messaggio, chi ha inventato i casi li pone e l'autore delle istruzioni risponde applicando alla lettera solo le regole che ha scritto, e lo scrive nei casi

I file consegnati sono gli stessi: cambia la nota su come sono stati ottenuti.

Problemi probabili

Sintomo	Possibile causa	Che cosa fare
Il comando di installazione dà errore subito	Criteri di esecuzione di PowerShell o rete	Copiare il messaggio e verificare con un'altra postazione; provare senza $env:UNSLOTH_NO_TORCH=1;
L'installazione non finisce	Rete saturata da tutte le postazioni	Proseguire con la parte 2; alla fine della parte 2 applicare la regola di «Se l'installazione è lenta» (scrittura anticipata, poi ramo di riserva)

Sintomo	Possibile causa	Che cosa fare
Il download del modello resta a 0 %	Il metodo di download predefinito può bloccarsi su alcune reti	Chiudere Studio, in PowerShell scrivere $env:HF_HUB_DISABLE_XET=1 e poi unsloth studio -p 8888; oppure usare la cartella del modello su chiavetta
«Disk space is running low»	VM con poco spazio	Verificare lo spazio libero prima di scaricare il modello
Il PC reale rallenta	8 GB assegnati alla VM e il browser con Transformer Explainer	Chiudere altri programmi sul computer reale; una scheda per sito
La risposta non arriva	Modello troppo grande per la memoria, o testo lungo su CPU	Aspettare; con il registro intero la prima risposta può richiedere tempo, è un dato da misurare
La VM non risponde affatto	Memoria esaurita, per esempio con Context Length su Auto	Nella finestra di VMware Ctrl+Alt+Ins e Gestione attività, chiudere il processo di Studio; in ultima istanza menu VM, Power, Restart Guest; poi riaprire Studio come nella consegna

Dati da raccogliere per le lezioni 5–7

Prima di riprendere con la lezione 5 (18 novembre): quante VM hanno finito l'installazione, con quale metodo è arrivato il modello e quanto ha impiegato; memoria e secondi di risposta; quali istruzioni di sistema sono state seguite e quali ignorate dal modello da 2 miliardi di parametri; che cosa è passato dal campo System Prompt e che cosa no.