Finanziato dall'Unione europea NextGenerationEU
Ministero dell'Istruzione e del Merito
Italiadomani PIANO NAZIONALE DI RIPRESA E RESILIENZA
FUTURA LA SCUOLA PER L'ITALIA DI DOMANI

ITS MAKER ACADEMY · BOLOGNA

Un assistente sul computer del reparto

Lezione 4 · Unsloth Studio e istruzioni di sistema

12 novembre 2026 · Unsloth Studio nella macchina virtuale

ITSMAKER ACADEMY
ISTITUTO TECNOLOGICO SUPERIORE
WWW.ITSMAKER.IT

MECCANICA, MECCATRONICA,
MOTORISTICA E PACKAGING

La richiesta del responsabile

«I registri della pressa P03 non devono uscire dal reparto. Vorrei un assistente che lavori sul nostro computer.»

Il modello che usate oggi gira dentro la vostra macchina virtuale: i testi che gli date non vanno a un servizio esterno.

Il caso è quello che conoscete: la pressa P03 e il registro del 13–15 ottobre.

Il percorso di oggi

Parte	Dove lavorate	Che cosa ottenete
1. Installare Unsloth Studio	Macchina virtuale	Programma e modello pronti
2. Capire come risponde un modello	Computer reale, browser	Previsioni e numero di token
3. Misurare e regolare	Unsloth Studio	misure_VM.txt
4. Scrivere le istruzioni dell'assistente	Unsloth Studio	istruzioni_assistente_P03.txt e casi_di_prova.txt

In coppia, ognuno con la propria macchina virtuale. I tre file si scrivono con Blocco note dentro la macchina virtuale.

01

Installiamo Unsloth Studio

Il programma che fa girare il modello.

L'installazione, nella macchina virtuale

Nella macchina virtuale aprite PowerShell: menu Start, scrivete PowerShell, premete Invio.

Incollate questa riga e premete Invio. Dice a Windows di scaricare e avviare il programma di installazione:

$env:UNSLOTH_NO_TORCH=1; irm https://unsloth.ai/install.ps1 | iex

- Non chiudete la finestra: scarica molti file e può metterci a lungo.
- Se compare un errore in rosso, chiamate il docente.
- Intanto aprite Teams nella macchina virtuale e scaricate il registro; copiate lo zip del modello sul Desktop e restituite la chiavetta; create in Documenti i tre file .txt vuoti. Poi la parte 2 sul computer reale.

02

Come sceglie la parola successiva

Un modello piccolo che si vede all'opera.

Transformer Explainer

Sul computer reale, nel browser: poloclub.github.io/transformer-explainer

È un modello piccolo che completa frasi in inglese: non è un assistente.

1. Scrivete una frase breve in inglese e guardate quali parole propone dopo.
2. Prima di muovere la temperatura, scrivete in misure_VM.txt, nella macchina virtuale, che cosa pensate che succeda alle probabilità se la alzate e se la abbassate.
3. Provate. Poi scrivete che cosa avete visto e spiegatelo al compagno.

Si osservano le probabilità: non c'è un errore da trovare.

Quanto pesa il testo

Il modello legge pezzi di testo, i token. Sul computer reale: huggingface.co/spaces/Xenova/the-tokenizer-playground

1. Incollate il testo del registro. Scegliete il tokenizzatore dal menu in alto e scrivete in misure_VM.txt il suo nome e i token.
2. Riscrivete voi il testo più breve nella casella, con gli stessi fatti importanti, e scrivete il nuovo numero.
3. Leggete la versione breve del compagno: quale fatto importante ha tolto?

Installazione non finita alla fine di questa parte? Avvisate il docente.

03

Il modello sul vostro computer

Avviamo Studio e carichiamo il modello.

Il primo avvio

Quando l'installazione finisce, PowerShell chiede se avviare Unsloth Studio: scrivete Y e premete Invio.

1. Nel browser della macchina virtuale aprite http://127.0.0.1:8888 e create una password di almeno 8 caratteri. Scrivetela su un foglio.
2. Chiudete la scheda di Teams e aprite Gestione attività: Ctrl+Maiusc+Esc, Prestazioni, Memoria.
3. Scrivete in misure_VM.txt la memoria in uso prima di caricare il modello.

Il modello

1. Zip sul Desktop? Estraetelo in %USERPROFILE%\.cache\huggingface\hub e controllate la cartella models--unsloth--Qwen3.5-2B-GGUF.
2. Aspettate l'indicazione del docente su Context Length.
3. Cliccate Select model: con lo zip aprite On Device, altrimenti cercate unsloth/Qwen3.5-2B-GGUF e scegliete UD-Q4_K_XL.
4. Search e Tools all'inizio sono attivi (verdi): cliccateli, devono diventare grigi.

Memoria quasi al massimo? Slide 13.

Che cosa occupa il modello

Studio stima la memoria in Run settings. La misura vera è in Gestione attività.

Quando	Che cosa scrivete in misure_VM.txt
Modello caricato, Context Length su Auto	Stima di Studio e memoria in uso
Context Length 8192, poi Reload model	Stima di Studio e memoria in uso
Domanda breve	Secondi dal tasto Invio alla prima parola, e tok/s
Registro intero con una domanda	Secondi, tok/s e token usati

tok/s: token al secondo. 1.5k: circa 1.500 token. Context Length: token tenuti presenti. Token di Studio e del Tokenizer: uguali?

Se Studio si blocca

Se la macchina virtuale rallenta molto o la finestra non risponde: chiudete la finestra di PowerShell in cui gira Studio, scrivete «bloccato» nella prima riga della tabella di 3B e avvisate il docente.
Per riaprire Studio: nuova finestra di PowerShell, unsloth studio -p 8888, Invio. Nel browser aprite http://127.0.0.1:8888, Select model, On Device, il modello. Poi in Run settings portate Context Length a 8192 e cliccate Reload model.

Regolare le risposte

Insieme: decidete come giudicherete una risposta. Scrivete i dati del fermo del 14 ottobre da trovare nel registro, come li controllerete e la richiesta che farete.
Poi in Run settings dividetevi le regolazioni: uno prova Temperature, l'altro Top P oppure Top K, a scelta.

- Temperature: bassa, risposte più prevedibili; alta, più varietà.
- Top P e Top K: limitano le parole tra cui il modello può scegliere.

I valori di partenza li prova chi segue Temperature; poi ognuno prova un valore basso e uno alto. Scegliete insieme e scrivete in misure_VM.txt quale impostazione e perché.

04

Le istruzioni dell'assistente

Che cosa deve fare, e come.

Le istruzioni di sistema

In Run settings c'è la casella System Prompt: le istruzioni scritte lì valgono per tutta la conversazione. Il messaggio che scrivete nella chat è un'altra cosa.
Scrivete in istruzioni_assistente_P03.txt le istruzioni per un assistente di reparto:

- che cosa deve fare e da quali fonti può rispondere;
- quando deve farvi una domanda prima di rispondere;
- che cosa non deve fare;
- come deve rispondere.

Provate le vostre istruzioni

1. Incollate le istruzioni nella casella System Prompt e usate l'impostazione che avete scelto.
2. Aprite una nuova conversazione e incollate in un solo messaggio il registro e, sotto, la vostra domanda.
3. Guardate se l'assistente rispetta le istruzioni.

Le istruzioni non servono a farlo rispondere bene a qualunque domanda: servono a dire come deve comportarsi quando la domanda è incompleta o fuori dal registro.

Mettetevi alla prova

Mandatevi il testo delle istruzioni con un messaggio su Teams. Poi ognuno prova l'assistente del compagno nel proprio Studio.

Inventate voi almeno quattro casi di prova e tranelli: che cosa può sfuggire a un assistente che legge solo questo registro?

In casi_di_prova.txt, per ogni caso: la domanda, la risposta ricevuta, OK oppure ERRORE e perché.

Ogni prova in una nuova conversazione.

Correggete le istruzioni

Rileggete i casi del compagno sul vostro assistente.

Per ogni ERRORE decidete che cosa correggere: le istruzioni, la domanda o il testo dato all'assistente.

Correggete le regole nel testo delle istruzioni e scrivete sotto «Correzioni dopo le prove» che cosa avete cambiato, il motivo e l'esito. Tutti OK?

Scrivete quale regola ha funzionato e aggiungete la regola per un caso nuovo. In System Prompt incollate solo le regole e riprovate.

Le consegne

Ognuno consegna i propri tre file .txt nel compito su Teams, dal browser della macchina virtuale oppure dal computer reale:

File	Contenuto
misure_VM.txt	Previsioni, token, misure, spiegazione, criteri, scelta
istruzioni_assistente_P03.txt	Istruzioni e correzioni dopo le prove
casi_di_prova.txt	I casi inventati per il compagno e gli esiti

Se Studio non parte

Se l'installazione non è finita quando avete terminato la parte 2, avvisate il docente. Se una sola macchina virtuale della coppia funziona, lavorate a turno su quella.

- Memoria: octooai.com/llm-vram-calculator, modello da 2 miliardi di parametri a 4 bit, contesto 8192 e massimo. È una stima.
- Regolazioni: scegliete una temperatura con Transformer Explainer e scrivete perché.
- Istruzioni: provatele in Copilot. Non è System Prompt, e il registro esce dal reparto: scrivetelo. Copilot non risponde? Chi ha inventato i casi li pone, l'autore risponde con le sole regole scritte.

Che cosa avete verificato?

Che cosa occupa un modello sul vostro computer, e che cosa cambia con testi lunghi?

Che cosa cambia la temperatura nelle risposte?

Quale caso di prova vi ha fatto cambiare o confermare le istruzioni?

ITSMAKER ACADEMY
ISTITUTO TECNOLOGICO SUPERIORE

WWW.ITSMAKER.IT